FACULDADE ANTÔNIO MENEGHETTI
Sistemas de Informação
Pré-projeto do Trabalho de Conclusão de Curso

NÍCOLAS MARIN CORNELI

Aplicativo Mobile com Inteligência Artificial para Simulação Capilar e Gestão de Clientes em Serviços de Beleza

Orientador(a): Tarcisio Ceolin Junior

Estr. Recanto Maestro, 338, Restinga Sêca
Restinga Sêca, RS
2026

SUMÁRIO

1 INTRODUÇÃO 3
1.1 Problema de pesquisa e delimitação 4
1.2 Trabalhos correlatos, diferencial competitivo e lacuna 4
2 JUSTIFICATIVA 5
3 OBJETIVOS 7
4 REFERENCIAL TEÓRICO 7
4.1 Inteligência Artificial generativa aplicada a imagens 7
4.2 Visão computacional para segmentação e manipulação capilar 8
4.3 Virtual try-on e apoio à tomada de decisão estética 9
4.4 Qualidade perceptiva, usabilidade e confiança no sistema 11
4.5 Aplicativos mobile, integração de serviços e gestão de clientes 11
5 METODOLOGIA 12
5.1 Caracterização da pesquisa e abordagem metodológica 12
5.2 Procedimentos metodológicos com DSDM 14
5.3 Requisitos do sistema 15
5.4 Stack tecnológica 17
5.5 Arquitetura do sistema 17
5.6 Modelagem do banco de dados 18
5.7 Requisitos funcionais e modelagem do fluxo de decisão 19
5.8 Pipeline de simulação capilar 20
5.9 Protótipo de telas: wireframes descritivos 21
5.10 Instrumentos de coleta e método de validação do sistema 22
5.11 Aspectos éticos, privacidade e LGPD 23
5.12 Riscos e estratégias de mitigação 24
6 RESULTADOS PARCIAIS E ESPERADOS 25
6.1 Resultados parciais 25
6.2 Entrega do sistema: o que o protótipo fará 26
6.3 Resultados esperados 26
6.4 Indicadores de sucesso 27
7 CRONOGRAMA DE ATIVIDADES 27
REFERÊNCIAS BIBLIOGRÁFICAS 28

1 INTRODUÇÃO

O setor de beleza, sobretudo no contexto de pequenos salões, barbearias e profissionais autônomos, caracteriza-se por serviços fortemente personalizados, nos quais as decisões são intensamente influenciadas pela percepção estética do cliente. No recorte capilar, escolhas relacionadas a corte, comprimento, volume e coloração costumam ser construídas a partir de descrições verbais, fotografias de referência e da experiência prática do profissional. Embora esse processo esteja consolidado no cotidiano do atendimento, ele apresenta limitações recorrentes, como subjetividade interpretativa, desalinhamento de expectativas e dificuldade de antecipação visual do resultado.

Em paralelo, a evolução recente da Inteligência Artificial (IA) aplicada a imagens, particularmente por meio de modelos generativos e técnicas de edição condicionada, amplia a possibilidade de produzir simulações visuais mais realistas e controláveis (HO; JAIN; ABBEEL, 2020; ROMBACH et al., 2022). No domínio capilar, estudos recentes investigam transferência de penteados, preservação de identidade facial e manipulação de cor e textura, com resultados promissores para aplicações de virtual try-on (KHWANMUANG et al., 2023; ZHAO et al., 2024; NAIR; VARGHESE, 2025). Esse avanço tecnológico sugere potencial relevante para apoiar a tomada de decisão em serviços estéticos personalizados.

Apesar desse desenvolvimento técnico, permanece uma distância significativa entre protótipos acadêmicos com alto desempenho visual e sistemas de informação efetivamente utilizáveis na rotina de micro e pequenos negócios. Em muitos casos, as soluções disponíveis concentram-se na demonstração algorítmica e dedicam atenção limitada a requisitos operacionais, como cadastro de clientes, histórico de serviços, organização de agenda e continuidade do atendimento (KHWANMUANG et al., 2023; ZHAO et al., 2024; SUNG; CHIN, 2023). Nesse sentido, torna-se pertinente investigar como integrar um módulo de simulação capilar por IA a um aplicativo mobile com funcionalidades de gestão, preservando equilíbrio entre viabilidade técnica, custo e usabilidade.

Diante desse cenário, este pré-projeto propõe o desenvolvimento de um aplicativo mobile que articule dois eixos complementares: (i) simulação capilar assistida por IA, com a finalidade de apoiar a decisão estética antes da execução do serviço; e (ii) funcionalidades de gestão de clientes, histórico e agendamentos, voltadas ao suporte do fluxo operacional do salão. A proposta adota uma arquitetura composta por aplicativo em React Native, backend em FastAPI, banco de dados PostgreSQL e consumo de serviço externo de geração de imagens,

com foco em prototipagem funcional e avaliação aplicada ao contexto de pequenos serviços de beleza.

Do ponto de vista da organização textual, o documento está estruturado em sete seções principais: introdução, justificativa, objetivos, referencial teórico, metodologia, resultados parciais e esperados e cronograma de atividades, seguidas das referências bibliográficas.

1.1 Problema de pesquisa e delimitação

A questão central que orienta este pré-projeto pode ser sintetizada nos seguintes termos: como desenvolver uma solução mobile, tecnicamente viável e útil ao contexto de pequenos serviços de beleza, que integre simulação capilar por IA e funcionalidades de gestão de clientes para apoiar a tomada de decisão no atendimento?

A delimitação do estudo considera quatro recortes principais: (i) o desenvolvimento de um protótipo funcional, e não de um produto comercial final; (ii) o uso de serviço externo de IA para inferência, sem treinamento de modelo proprietário; (iii) a realização de avaliação exploratória com amostra de 5 a 10 participantes, compatível com o escopo de um TCC; e (iv) a concentração no fluxo de atendimento capilar, cadastro, histórico, agenda e simulação, sem abranger outros serviços estéticos.

Tal delimitação torna o projeto exequível no prazo acadêmico e, ao mesmo tempo, preserva o rigor metodológico, ao concentrar esforços na integração entre componentes, na coerência arquitetural e na validação inicial da utilidade da solução proposta. Essa escolha é deliberada e fundamentada: treinar um modelo proprietário de difusão para manipulação capilar demandaria dataset rotulado de milhares de pares de imagens antes e depois, infraestrutura de GPU de alto custo e meses de trabalho, o que é inviável no escopo de um TCC. Consumir um serviço externo de inferência permite, portanto, concentrar o esforço de desenvolvimento na qualidade do sistema de informação que articula a simulação à gestão do relacionamento com o cliente. Essa articulação entre simulação visual e gestão do relacionamento é, em última instância, a contribuição original deste trabalho.

1.2 Trabalhos correlatos, diferencial competitivo e lacuna

No estado da arte, identificam-se contribuições relevantes em pelo menos três frentes. A primeira diz respeito ao avanço dos modelos de difusão e da representação latente para geração e edição de imagens, possibilitando resultados de elevada fidelidade visual (HO; JAIN; ABBEEL, 2020; ROMBACH et al., 2022). A segunda reúne pesquisas específicas de

manipulação capilar, com ênfase em robustez à pose, transferência de estilo e separação de atributos visuais (KHWANMUANG et al., 2023; ZHAO et al., 2024; SKLYAROVA et al., 2024). A terceira envolve aplicações de virtual try-on, voltadas à experimentação estética sem contato físico e ao apoio à escolha do usuário (SUNG; CHIN, 2023; NAIR; VARGHESE, 2025).

Ainda assim, as publicações analisadas dedicam menor atenção à integração dessas capacidades com sistemas de informação orientados à operação cotidiana de pequenos negócios. Em geral, permanecem pouco explorados aspectos como manutenção do histórico de atendimento, persistência de preferências do cliente, rastreabilidade das decisões tomadas e articulação com a agenda de serviços. É nessa lacuna que o presente projeto se insere, buscando transformar capacidade algorítmica em utilidade operacional no contexto real do atendimento capilar.

Essa lacuna também se manifesta no comparativo com soluções comerciais já disponíveis ao mercado. Aplicativos de edição de selfie como o YouCam Makeup oferecem simulação visual de penteado e de cor de cabelo por meio de IA, voltada à experimentação estética individual e ao compartilhamento em redes sociais, mas sem qualquer integração com cadastro de clientes, histórico de atendimento ou agenda de um negócio (PERFECT CORP, 2026). Em sentido complementar, sistemas de gestão voltados a salões e barbearias, como o Booksy, oferecem agendamento on-line, cadastro e histórico de clientes e ferramentas de relacionamento, mas não incorporam simulação visual por IA como etapa do fluxo de decisão estética (BOOKSY, 2026). O diferencial deste projeto está precisamente na convergência dessas duas dimensões, hoje oferecidas de forma fragmentada pelo mercado: um único fluxo que parte da simulação visual e encadeia o resultado ao histórico do cliente, à agenda e às preferências registradas, transformando capacidade algorítmica em utilidade operacional para pequenos negócios de beleza.

2 JUSTIFICATIVA

A realização deste trabalho justifica-se pela convergência de argumentos sociais, práticos, técnicos e acadêmicos. Em termos gerais, a proposta responde à necessidade de aproximar avanços recentes da IA aplicada a imagens de problemas concretos enfrentados por pequenos prestadores de serviços de beleza, especialmente em atividades nas quais a decisão estética depende de comunicação clara e de confiança entre profissional e cliente.

Na dimensão social e econômica, o projeto dialoga com um contexto de microempreendedorismo relevante no mercado brasileiro de serviços pessoais. Pequenos salões e profissionais independentes frequentemente operam com baixa digitalização e com recursos limitados para a adoção de tecnologias avançadas (COSTA et al., 2022; KOKONG; NAIDOO, 2022). Essa limitação é corroborada por dados nacionais recentes: segundo o levantamento de maturidade digital realizado pela ABDI em parceria com o Sebrae, apenas 36% dos pequenos negócios brasileiros possuem algum sistema de gestão de clientes com coleta de dados, e somente 27% utilizam um sistema de gestão que integre as informações de todas as áreas do negócio (ABDI; SEBRAE, 2024). Esse cenário de baixa maturidade digital contrasta com o porte econômico do setor: o mercado brasileiro de beleza e cuidados pessoais é o terceiro maior do mundo, atrás apenas de Estados Unidos e China, com faturamento anual estimado em US$ 26,9 bilhões e projeção de crescimento médio de 7,2% ao ano até 2027 (ABIHPEC, 2025). Nesse contexto, uma solução mobile de uso simples e com potencial de baixo custo incremental pode ampliar o acesso a recursos de IA antes restritos a plataformas de maior investimento, contribuindo também para reduzir a lacuna de gestão identificada nacionalmente.

Na dimensão prática, o sistema busca reduzir incertezas na comunicação entre cliente e profissional. A visualização simulada de opções de corte e cor tende a aumentar a clareza do atendimento, reduzir retrabalho e apoiar decisões mais informadas. Além disso, a integração entre cadastro de clientes, histórico de serviços e agenda fortalece a continuidade do relacionamento e a organização do processo operacional, aspecto coerente com princípios de gestão de relacionamento com clientes (PAYNE; FROW, 2005).

Na dimensão técnica, a proposta se mostra pertinente por combinar técnicas contemporâneas de visão computacional e modelos generativos com uma arquitetura orientada a serviços, em abordagem incremental e viável para um trabalho de conclusão de curso. O uso de APIs de IA permite concentrar esforços no desenho do sistema, na governança do fluxo de dados e nos critérios de qualidade da solução, sem exigir o treinamento integral de modelos de grande porte em ambiente local (ROMBACH et al., 2022; HEVNER et al., 2004).

Na dimensão acadêmica, a pesquisa contribui ao investigar a articulação entre o estado da arte em manipulação capilar por IA e sua implementação em um sistema aplicado a um problema real de negócio. A lacuna principal não se restringe à qualidade visual dos modelos, mas envolve a relação entre desempenho técnico, experiência de usuário, requisitos de software

e utilidade no processo de decisão em serviços personalizados (HEVNER et al., 2004; DAVIS, 1989).

3 OBJETIVOS

O objetivo geral desta pesquisa é desenvolver e avaliar um aplicativo mobile com módulo de simulação capilar por IA e funcionalidades de gestão de clientes, de modo a apoiar a tomada de decisão em serviços de beleza.

Para alcançar esse objetivo geral, definem-se os seguintes objetivos específicos:

- Levantar e sistematizar fundamentos teóricos sobre IA generativa, modelos de difusão, visão computacional aplicada a cabelo e sistemas de virtual try-on.
- Definir requisitos funcionais e não funcionais do aplicativo, contemplando simulação capilar, cadastro de clientes, histórico de atendimento e agenda.
- Projetar a arquitetura de software do sistema, abrangendo camadas mobile, backend, banco de dados e serviço de IA, bem como o fluxo de dados e os pontos de integração.
- Implementar um protótipo funcional em React Native e FastAPI, com persistência em PostgreSQL e armazenamento das imagens associadas às simulações no Supabase Storage.
- Integrar um pipeline de geração de imagem baseado em modelo de difusão, com entrada por foto do usuário, referência de estilo e parâmetro de cor.
- Avaliar o protótipo com base em métricas de qualidade percebida da simulação, utilidade para a decisão e usabilidade básica por potenciais usuários.
- Sistematizar diretrizes de design para a integração de serviços externos de IA generativa a sistemas de gestão de pequenos negócios, descrevendo os limites, riscos e requisitos de governança identificados ao longo do desenvolvimento.
- Documentar limitações técnicas, riscos éticos e diretrizes de evolução para o trabalho final.

4 REFERENCIAL TEÓRICO

4.1 Inteligência Artificial generativa aplicada a imagens

Os fundamentos de IA empregados neste trabalho dialogam com a concepção de sistemas capazes de perceber, representar e atuar diante de problemas complexos sob incerteza

(RUSSELL; NORVIG, 2021). No domínio visual, os avanços mais expressivos dos últimos anos decorrem da consolidação de modelos generativos capazes de sintetizar ou editar imagens com alto grau de realismo. Entre essas abordagens, os modelos de difusão se destacam por modelarem a geração como um processo iterativo de remoção de ruído, no qual a imagem final emerge gradualmente a partir de uma distribuição probabilística (HO; JAIN; ABBEEL, 2020). Esse princípio favorece um controle mais fino sobre atributos visuais e reduz parte dos artefatos típicos de arquiteturas generativas anteriores.

Ao operar em espaço latente, os modelos propostos por Rombach et al. (2022) tornam esse paradigma mais viável para aplicações práticas, pois reduzem o custo computacional sem perda substancial de qualidade perceptiva. Para este pré-projeto, essa característica é decisiva: em vez de treinar localmente um modelo de grande porte, o sistema pode consumir um serviço externo de inferência e concentrar o esforço de desenvolvimento na experiência do usuário, na integração entre módulos e na governança do fluxo de dados. Em termos práticos, uma fotografia do cliente, acompanhada de uma referência de estilo e de parâmetros de cor, pode ser processada remotamente e devolvida ao aplicativo como uma simulação visual utilizável durante o atendimento.

Outro ponto central diz respeito ao caráter condicionado da geração. Em uma aplicação capilar, o objetivo não é produzir uma imagem qualquer, mas uma edição coerente com a identidade facial do usuário e com a intenção estética informada. Esse requisito aproxima o projeto de tarefas de tradução imagem a imagem (image-to-image translation), edição guiada por atributos e preservação de identidade, nas quais a qualidade do resultado depende tanto do modelo generativo quanto do pré-processamento e da especificação dos parâmetros de entrada. Assim, o valor da IA neste caso não se resume à automação, mas à sua capacidade de apoiar a comunicação visual entre profissional e cliente por meio de uma representação antecipada do possível resultado do serviço.

4.2 Visão computacional para segmentação e manipulação capilar

A manipulação digital de cabelo constitui um problema particularmente desafiador para a visão computacional. Diferentemente de regiões faciais com contornos mais estáveis, o cabelo apresenta fios finos, bordas irregulares, transparências parciais, oclusões, reflexos e grande variabilidade de textura. Essas características ampliam a dificuldade de segmentação e tornam a edição mais sensível a erros localizados. Métodos de segmentação de instâncias, como o Mask R-CNN (HE et al., 2017), oferecem base importante para delimitar regiões de interesse e apoiar

tarefas de recorte semântico, mascaramento e preparação da imagem para a geração condicionada.

No recorte específico de penteados, Jang, Man e Cho (2022) investigam um sistema de conversão apoiado por segmentação, demonstrando que a qualidade da delimitação da região capilar influencia diretamente a naturalidade do resultado. De forma complementar, Khwanmuang et al. (2023) exploram otimização latente multi-visão para transferência de penteados robusta à pose, problema recorrente em cenários reais nos quais o usuário nem sempre fornece uma imagem frontal ideal. Já Zhao et al. (2024) propõem a separação de elementos capilares para melhorar o controle de edição, indicando que o tratamento de atributos como forma, direção dos fios e textura contribui para resultados mais consistentes.

Esses achados têm implicações diretas para o sistema proposto. Em um salão ou atendimento autônomo, é plausível que a fotografia seja capturada sob iluminação variável, fundo não padronizado e enquadramento imperfeito. Nessa situação, um pipeline minimamente robusto precisa contemplar validação de imagem, padronização de dimensões e controle básico de qualidade antes da inferência. Um exemplo prático consiste em rejeitar imagens excessivamente escuras ou com o rosto parcialmente encoberto, orientando o usuário a repetir a captura. Essa etapa simples não substitui a capacidade do modelo, mas reduz a probabilidade de resultados visualmente inconsistentes e melhora a experiência de uso.

É relevante reconhecer, criticamente, que os modelos atuais ainda apresentam limitações conhecidas na literatura: os resultados podem degradar-se em cabelos muito escuros, loiros platinados ou com texturas afro; iluminação variável e fundo não padronizado afetam a fidelidade da segmentação; e fotografias em ângulo não frontal reduzem a qualidade do resultado final (KHWANMUANG et al., 2023). Essas limitações devem ser comunicadas ao usuário de forma transparente e compõem os critérios de qualidade mínima estabelecidos para a aceitação da imagem de entrada no pipeline do sistema, conforme detalhado na seção de metodologia.

4.3 Virtual try-on e apoio à tomada de decisão estética

O conceito de virtual try-on refere-se ao uso de recursos computacionais para simular digitalmente um produto, estilo ou modificação antes da decisão final do usuário. Em aplicações estéticas, o principal valor não está apenas na visualização, mas na mediação entre a expectativa subjetiva e a execução concreta do serviço. No caso capilar, essa mediação é especialmente

importante porque corte e coloração envolvem alto componente simbólico e impacto direto na autoimagem do cliente. Trabalhos como os de Sung e Chin (2023) e Nair e Varghese (2025) evidenciam que sistemas de experimentação virtual podem ampliar o engajamento, facilitar a comparação entre alternativas e reduzir o caráter abstrato da decisão.

Entretanto, a utilidade desses sistemas depende da integração entre qualidade visual, clareza da interação e contexto de uso. Uma simulação tecnicamente sofisticada, mas dissociada do fluxo de atendimento, tende a ter valor limitado em pequenos negócios. Por isso, neste projeto, o virtual try-on é concebido como instrumento de apoio à decisão e à comunicação, e não como substituto da avaliação profissional. O objetivo é oferecer ao cliente uma prévia plausível o suficiente para apoiar a conversa, o alinhamento de expectativas e o registro de preferências.

Essa perspectiva permite compreender o módulo de IA como parte de um processo de serviço. Em termos práticos, o profissional pode registrar uma foto inicial, testar duas ou três alternativas de cor ou comprimento e salvar a opção escolhida no histórico do cliente. Em atendimentos futuros, esse histórico funciona como memória do relacionamento, reduzindo ambiguidades e apoiando maior personalização. Assim, a relevância do virtual try-on não reside somente na geração de uma imagem convincente, mas na forma como essa imagem passa a compor o fluxo de decisão e de gestão do atendimento.

É fundamental, entretanto, distinguir simulação de previsão: a imagem gerada representa uma aproximação visual plausível, e não uma reprodução fiel do resultado real. Fatores como a textura real do cabelo, o volume, o histórico químico do fio e as condições de iluminação no momento da captura podem produzir diferenças entre o resultado simulado e o resultado executado. Sistemas que não comunicam esse limite correm o risco de criar expectativas irreais no cliente, comprometendo a confiança no sistema e, por extensão, no próprio profissional que o utiliza (DAVIS, 1989).

Esse encadeamento entre captura, parametrização, processamento e uso operacional do resultado evidencia que o aspecto mais importante do fluxo não é apenas o retorno da imagem simulada, mas a incorporação desse artefato ao histórico do cliente, o que conecta experimentação visual e gestão do relacionamento.

4.4 Qualidade perceptiva, usabilidade e confiança no sistema

Em aplicações voltadas ao apoio à decisão, a qualidade do sistema deve ser analisada em múltiplas dimensões. A primeira delas é a qualidade visual percebida, que envolve naturalidade, coerência de cor, compatibilidade do penteado com a face e ausência de artefatos evidentes. A segunda é a usabilidade, entendida como o grau em que usuários conseguem atingir objetivos específicos com eficácia, eficiência e satisfação em determinado contexto de uso (INTERNATIONAL ORGANIZATION FOR STANDARDIZATION, 2018). A terceira é a utilidade percebida, isto é, o quanto a tecnologia efetivamente contribui para melhorar a decisão ou o desempenho da atividade (DAVIS, 1989).

No contexto deste projeto, essas três dimensões são interdependentes. Uma simulação visualmente realista, porém obtida por meio de um fluxo confuso ou lento, pode comprometer a adoção no ambiente de atendimento. Da mesma forma, uma interface simples, mas incapaz de gerar resultados críveis, tende a ser percebida como pouco útil. Por essa razão, a avaliação do protótipo precisa combinar critérios técnicos e perceptivos. Um exemplo prático é o caso em que o usuário considera a interface fácil de operar, mas rejeita o resultado por entender que a cor simulada não corresponde ao cabelo real; nesse cenário, a usabilidade isolada não é suficiente para validar a solução.

Outro aspecto relevante é a confiança. Como o sistema lida com autoimagem e expectativa estética, o usuário precisa compreender que a simulação representa uma aproximação visual, e não uma previsão exata do resultado. Essa compreensão depende de comunicação transparente sobre os limites técnicos, a qualidade mínima das imagens de entrada e as condições de uso. Desse modo, a confiança não decorre apenas do algoritmo, mas também da forma como o sistema orienta o usuário, apresenta o resultado e contextualiza a finalidade da simulação.

4.5 Aplicativos mobile, integração de serviços e gestão de clientes

Sob a ótica da engenharia de software, o projeto articula desenvolvimento cross-platform, backend orientado a serviços e persistência de dados voltada ao contexto operacional do atendimento. Conforme discutem Bjørn-Hansen, Grønli e Ghinea (2020), abordagens multiplataforma podem reduzir o esforço de desenvolvimento e manutenção quando há necessidade de atender múltiplos sistemas operacionais com escopo funcional semelhante. Para um protótipo acadêmico, o React Native mostra-se pertinente porque oferece integração com câmera, bibliotecas de interface e consumo de APIs, mantendo complexidade moderada.

No backend, a adoção de uma API em FastAPI permite centralizar regras de negócio, orquestração da inferência e persistência dos dados do domínio, além de validar a identidade do usuário a cada requisição. Essa separação favorece a escalabilidade lógica e facilita o tratamento de responsabilidades distintas: a aplicação móvel concentra-se na interação com o usuário, enquanto o backend controla validações, auditoria básica e integração com serviços externos. Já a base de dados relacional PostgreSQL, associada ao Supabase Storage para o armazenamento das imagens de simulação, oferece suporte à rastreabilidade completa do atendimento, o que é especialmente importante quando o sistema precisa vincular simulações, preferências, observações e agendamentos a clientes específicos.

A dimensão de gestão aproxima o projeto dos princípios de CRM, entendidos como estratégias e sistemas para organizar interações e qualificar o relacionamento com clientes (PAYNE; FROW, 2005). Em pequenos serviços de beleza, cadastro, histórico e agenda não constituem apenas funções administrativas: eles estruturam a continuidade do atendimento e criam memória operacional do relacionamento. Um exemplo prático é o registro de que determinado cliente aprovou uma simulação de corte médio com tom castanho acobreado, mas preferiu adiar a execução. Em novo atendimento, essa informação pode ser recuperada e comparada com novas possibilidades, aumentando a consistência do serviço prestado.

Em síntese, o referencial teórico aponta que a contribuição do projeto emerge da convergência entre três dimensões: a capacidade algorítmica de edição visual, a qualidade de interação em contexto mobile e o suporte informacional ao relacionamento com clientes. A lacuna identificada na literatura não está apenas na geração de imagens, mas na transformação dessa capacidade em utilidade operacional para pequenos negócios de beleza.

5 METODOLOGIA

5.1 Caracterização da pesquisa e abordagem metodológica

Esta pesquisa caracteriza-se como aplicada, de natureza exploratória e descritiva, com abordagem metodológica mista e orientação de desenvolvimento de artefato. É aplicada porque se dirige à solução de um problema concreto do contexto de serviços de beleza: a dificuldade de alinhar expectativa estética, visualização prévia e gestão do relacionamento com clientes. É exploratória porque investiga uma combinação ainda pouco consolidada entre simulação capilar por IA e funcionalidades de gestão em aplicativo mobile, demandando compreensão inicial de requisitos, limitações e oportunidades. É também descritiva porque, além de

desenvolver o protótipo, pretende registrar e analisar como os usuários percebem sua utilidade, usabilidade e qualidade visual (HEVNER et al., 2004; CRESWELL; PLANO CLARK, 2017).

Quanto à abordagem, o estudo adota uma perspectiva mista, combinando dados qualitativos e quantitativos. O componente qualitativo será importante para captar percepções, dificuldades, sugestões e níveis de confiança dos participantes durante o uso do protótipo. O componente quantitativo, por sua vez, permitirá organizar medidas descritivas sobre utilidade percebida, facilidade de uso e adequação visual mediante questionário estruturado. Essa combinação é pertinente porque o objeto de estudo envolve tanto o desempenho funcional do sistema quanto a experiência do usuário em uma decisão estética mediada por tecnologia (CRESWELL; PLANO CLARK, 2017; DAVIS, 1989; INTERNATIONAL ORGANIZATION FOR STANDARDIZATION, 2018).

Sob o ponto de vista da produção tecnológica, o trabalho adota a Design Science Research (DSR) como perspectiva de fundo, o que legitima a construção de um artefato computacional como forma válida de produção de conhecimento científico, pois propõe conceber, construir e avaliar um artefato destinado a resolver um problema prático e, simultaneamente, produzir conhecimento sobre sua aplicabilidade, seus limites e seus requisitos de evolução (HEVNER et al., 2004). Para que essa legitimação não se reduza à simples entrega de um sistema funcional, o conhecimento de design que este trabalho pretende generalizar está delimitado a três frentes: (i) diretrizes para a integração de serviços externos de IA generativa a sistemas de gestão voltados a pequenos negócios, com foco na governança da dependência de provedores terceiros; (ii) critérios de validação de entrada de imagem que equilibram robustez técnica e experiência de uso em ambientes de captura não controlados; e (iii) requisitos de transparência necessários para que uma simulação visual seja percebida como apoio à decisão, e não como previsão exata, sem comprometer a confiança do usuário no sistema. Contudo, o método operacional principal que governa o processo de desenvolvimento incremental, a priorização de funcionalidades e os ciclos de validação com usuários é o Dynamic Systems Development Method (DSDM).

Essa distinção é importante: o DSR responde por que construir um artefato é pesquisa, enquanto o DSDM responde como o artefato será construído de forma controlada e iterativa. A combinação é coerente com o escopo de um TCC que tem como produto principal um protótipo funcional avaliado em contexto real de uso, e evita a ambiguidade epistemológica de tratar o desenvolvimento de software apenas como execução técnica, sem caráter investigativo.

5.2 Procedimentos metodológicos com DSDM

Para organizar o desenvolvimento do protótipo, será adotado o Dynamic Systems Development Method (DSDM), método ágil orientado à entrega incremental, ao envolvimento frequente dos interessados e ao controle do escopo por priorização (AGILE BUSINESS CONSORTIUM, 2014). A escolha do DSDM se justifica por três razões principais. Primeiro, o projeto possui prazo acadêmico delimitado, de julho a novembro de 2026, o que exige planejamento por incrementos e foco em funcionalidades essenciais. Segundo, o sistema combina componentes com diferentes graus de incerteza técnica, como interface mobile, backend, persistência e integração com IA, o que torna conveniente uma abordagem iterativa com validação frequente. Terceiro, o problema investigado depende fortemente da percepção do usuário, o que demanda ciclos curtos de prototipação e refinamento.

No DSDM, o desenvolvimento é guiado por princípios como foco na necessidade de negócio, entrega no prazo, colaboração, qualidade contínua e construção incremental a partir de bases firmes (AGILE BUSINESS CONSORTIUM, 2014). No contexto deste trabalho, a necessidade de negócio corresponde à melhoria do processo de atendimento e de comunicação entre profissional e cliente. A colaboração se materializa na coleta contínua de feedback de potenciais usuários e na validação de requisitos ao longo das iterações. Já a entrega no prazo é especialmente relevante para um pré-projeto de TCC, no qual o escopo precisa ser mantido compatível com o calendário acadêmico.

A aplicação do DSDM ao projeto será organizada em cinco momentos principais:

1. Pré-projeto e estudo de viabilidade: delimitação do problema, definição do recorte do TCC, análise preliminar de viabilidade técnica e escolha das tecnologias-base. Nessa fase, verifica-se se o uso de serviço externo de IA é compatível com o escopo, o orçamento e o prazo do trabalho.
2. Fundamentos e requisitos: revisão bibliográfica, identificação dos atores do sistema, levantamento de requisitos funcionais e não funcionais e definição da arquitetura macro. Nessa fase também serão estabelecidos critérios de qualidade, privacidade e avaliação.
3. Desenvolvimento iterativo: implementação incremental do aplicativo mobile, do backend e da camada de persistência. Cada iteração deverá entregar um conjunto pequeno e verificável de funcionalidades, como autenticação, cadastro de clientes, agenda e simulação capilar.

4. Validação do protótipo: execução de testes técnicos e aplicação do protótipo a participantes-alvo, com coleta de dados sobre utilidade, clareza do fluxo, confiança na simulação e desempenho percebido.

5. Ajustes e documentação: consolidação dos achados, correções prioritárias, registro das limitações e sistematização das lições aprendidas para a continuidade no TCC final.

Uma prática importante do DSDM é a priorização por níveis de importância. Neste projeto, essa lógica será operacionalizada por uma adaptação do critério MoSCoW, classificando funcionalidades em must have, should have, could have e won't have for now (AGILE BUSINESS CONSORTIUM, 2014). Como must have, incluem-se autenticação básica, cadastro de clientes, execução da simulação e salvamento no histórico. Como should have, enquadram-se a agenda integrada e o registro de observações do atendimento. Como could have, considera-se a comparação lado a lado entre múltiplas simulações. Já a recomendação automática de penteado por perfil biométrico permanece fora do escopo atual, por aumentar significativamente a complexidade técnica e ética. Essa priorização, detalhada por item individual na subseção 5.3.1, orienta diretamente a sequência de implementação apresentada no cronograma da seção 7.

Outra prática do DSDM pertinente ao projeto é o desenvolvimento iterativo com demonstrações frequentes. Em vez de aguardar a conclusão integral do sistema, cada ciclo buscará produzir um incremento funcional passível de observação e ajuste. Por exemplo, uma primeira iteração pode validar apenas o cadastro de clientes e o fluxo de captura de imagem; uma segunda pode incorporar o envio ao serviço de IA; e uma terceira pode integrar histórico e agenda. Esse encadeamento reduz risco, facilita o diagnóstico de problemas e torna o processo mais aderente ao tempo disponível para o TCC.

5.3 Requisitos do sistema

5.3.1 Requisitos funcionais

Os requisitos funcionais identificados para o protótipo, priorizados segundo o critério MoSCoW, estão sistematizados na Tabela 1. A organização por identificador individual favorece a rastreabilidade entre requisito, iteração de desenvolvimento e critério de aceitação na validação final.

ID	Funcionalidade	Descrição	Prior.
RF01	Autenticação do profissional	Login seguro via Supabase Auth, com sessão controlada por JWT validado pelo backend.	Must

RF02	Cadastro de clientes	CRUD completo: nome, contato, foto de perfil, observações.	Must
RF03	Histórico de atendimentos	Registro de serviços prestados, data, observações e simulações vinculadas.	Must
RF04	Simulação capilar por IA	Captura de foto, seleção de estilo e cor, envio à API externa e exibição do resultado.	Must
RF05	Persistência da simulação	Salvamento da imagem simulada no Supabase Storage, vinculada ao cliente.	Must
RF06	Agenda de serviços	Criação, edição e cancelamento de agendamentos com notificação local.	Should
RF07	Comparação de simulações	Exibição lado a lado de duas ou mais simulações do mesmo cliente.	Could
RF08	Recomendação automática de estilo	Sugestão de penteado com base em perfil facial; funcionalidade fora do escopo atual.	Won't

Tabela 1. Requisitos funcionais priorizados por MoSCoW. Fonte: elaborado pelo autor.

5.3.2 Requisitos não funcionais

Os requisitos não funcionais, com critérios mensuráveis de aceitação, são apresentados na Tabela 2. A definição de métricas quantitativas para cada atributo de qualidade, e não apenas descrições qualitativas, é o que permitirá avaliar objetivamente, ao final do protótipo, se os patamares mínimos de usabilidade, desempenho, segurança, confiabilidade, privacidade e portabilidade foram efetivamente atingidos.

Vale destacar que o requisito de desempenho (RNF02) depende de um serviço externo de inferência, fora do controle direto da equipe de desenvolvimento. Por esse motivo, ele é tratado como um patamar de referência monitorado, e não como uma garantia contratual, sendo associado a uma estratégia de degradação graciosa (tempo limite de espera, nova tentativa automática e mensagens claras ao usuário em caso de falha), detalhada nas seções 5.5 e 5.12.

ID	Atributo	Critério	Ref.
RNF01	Usabilidade	Tempo médio para completar a simulação inferior a 3 minutos.	ISO 9241-11
RNF02	Desempenho	Resposta da API de IA inferior a 30 s em 80% das requisições, monitorada como referência.	-
RNF03	Segurança	Comunicação via HTTPS/TLS 1.3; imagens criptografadas com AES-256 em repouso.	LGPD
RNF04	Confiabilidade	Disponibilidade mínima de 95% durante horário comercial, considerando o conjunto Supabase e Replicate API.	-
RNF05	Privacidade	Consentimento explícito para imagem facial; exclusão sob demanda (LGPD, art. 18).	LGPD
RNF06	Portabilidade	Compatível com Android 10+ e iOS 14+.	-

Tabela 2. Requisitos não funcionais com critérios mensuráveis. Fonte: elaborado pelo autor.

5.4 Stack tecnológica

A Tabela 3 sintetiza as tecnologias selecionadas para cada camada do sistema, com a respectiva justificativa de adoção. A inclusão de containerização via Docker, em particular, responde à necessidade de reprodutibilidade do ambiente de desenvolvimento, um aspecto frequentemente negligenciado em protótipos acadêmicos, mas relevante para a continuidade do projeto no TCC final.

Camada	Tecnologia	Justificativa
Frontend Mobile	React Native + Expo	Cross-platform (iOS/Android), acesso à câmera, bibliotecas de UI, ecossistema NPM.
Backend	Python 3.11 + FastAPI	Async nativo, tipagem forte, documentação OpenAPI automática, integração com bibliotecas de IA.
Banco de Dados	PostgreSQL via Supabase	Banco relacional maduro; Supabase fornece Storage, Auth e API REST prontos para uso.
Armazenamento de Imagens	Supabase Storage (compatível com S3)	Integrado ao banco, controle via Row-Level Security, URLs assinadas com TTL.
Serviço de IA	Replicate API (SDXL/img2img)	Inferência serverless, pagamento por uso, suporte a img2img e inpainting capilar.
Autenticação	Supabase Auth (provedor de identidade) + validação JWT pelo FastAPI	Supabase Auth emite o token; o backend valida a assinatura via JWKS a cada requisição e aplica RLS no PostgreSQL.
Containerização	Docker + Docker Compose	Ambiente reprodutível para desenvolvimento local e futura implantação em produção.

Tabela 3. Stack tecnológica com justificativa por camada. Fonte: elaborado pelo autor.

5.5 Arquitetura do sistema

A arquitetura proposta é composta por quatro camadas interdependentes. A camada de apresentação é o aplicativo em React Native/Expo, responsável pela interação com o usuário nos módulos de autenticação, gestão de clientes, histórico, agenda e simulador. A camada de aplicação é o backend em Python com FastAPI, que centraliza regras de negócio, validação e pré-processamento de imagens, e orquestração da inferência junto ao serviço externo de IA. A camada de dados é composta pelo PostgreSQL, hospedado via Supabase com Row-Level Security, e pelo Supabase Storage (compatível com S3), responsável pelo armazenamento criptografado das imagens de entrada e saída das simulações. A camada de IA é o serviço externo Replicate API, que executa a inferência de img2img com modelos SDXL e retorna a imagem simulada.

Quanto à autenticação, o Supabase Auth atua como provedor de identidade: valida as credenciais do profissional e emite o token JWT. A cada requisição, o backend em FastAPI

valida a assinatura desse token junto ao conjunto de chaves públicas do Supabase (JWKS) e utiliza as informações nele contidas para aplicar as regras de negócio, enquanto o PostgreSQL, por meio de Row-Level Security, restringe o acesso aos dados do profissional autenticado. Essa divisão evita que o FastAPI emita tokens próprios em paralelo ao Supabase Auth, o que poderia gerar duas fontes de verdade para a identidade do usuário.

O mobile acessa imagens do Storage diretamente por URLs assinadas, sem transitar pelo backend, reduzindo a latência na exibição dos resultados. Esse desenho busca garantir separação clara de responsabilidades e viabilidade incremental, favorecendo também a substituição futura do serviço de IA sem necessidade de reestruturar toda a aplicação, o que é desejável em projetos que dependem de provedores externos e de tecnologias em rápida evolução.

Por depender de dois provedores externos (Supabase e Replicate API), a arquitetura adota como princípio de resiliência o desacoplamento entre as funcionalidades essenciais de gestão e o módulo de simulação por IA: o cadastro de clientes, o histórico de atendimentos e a agenda permanecem operacionais mesmo em caso de indisponibilidade temporária do serviço de inferência, já que dependem apenas do banco de dados, e não do Replicate API. Esse desacoplamento é retomado como estratégia de mitigação na seção 5.12.

5.6 Modelagem do banco de dados

O banco de dados relacional PostgreSQL é composto por cinco entidades: usuarios, clientes, simulacoes, historico_servicos e agendamentos. A entidade simulacoes inclui a chave estrangeira usuario_id, que permite auditoria por profissional e é coerente com o requisito de segurança RNF03. O vínculo entre simulacoes e historico_servicos é opcional: um atendimento pode ser registrado sem simulação prévia, e uma simulação pode ser realizada sem resultar em serviço imediato.

Estruturalmente, o modelo relacional organiza-se em torno da entidade usuarios, que representa o profissional autenticado no sistema e atua como ponto de ancoragem para as demais entidades por meio da chave estrangeira usuario_id. A entidade clientes está vinculada a usuarios em relação obrigatória (1:N), de modo que cada profissional gerencia sua própria carteira de clientes, com isolamento garantido por Row-Level Security no Supabase.

A entidade simulacoes relaciona-se de forma obrigatória tanto com clientes quanto com usuarios, registrando, para cada simulação realizada, as URLs das imagens de entrada e saída,

os parâmetros utilizados (armazenados em formato JSON), o modelo de IA empregado e o tempo de processamento. Essa dupla referência permite tanto a recuperação do histórico de simulações por cliente quanto a auditoria das ações por profissional responsável.

A entidade historico_servicos representa os atendimentos efetivamente realizados e mantém vínculo obrigatório com clientes, mas relação opcional com simulacoes, já que nem todo atendimento decorre de uma simulação prévia, e nem toda simulação resulta necessariamente em serviço executado. Por fim, a entidade agendamentos vincula-se obrigatoriamente a clientes e a usuarios, armazenando data, horário, serviço previsto, status (pendente, confirmado, cancelado ou concluído) e observações, compondo a agenda operacional do profissional.

A Tabela 4 detalha os atributos principais de cada entidade, seus tipos de chave e a descrição funcional correspondente, consolidando textualmente as relações descritas acima.

Entidade	Atributos Principais	Tipo (chave)	Descrição
usuarios	id, email, senha_hash, nome, criado_em	PK: id (UUID)	Profissional que opera o sistema. Senha armazenada como hash bcrypt; identidade federada pelo Supabase Auth.
clientes	id, usuario_id, nome, telefone, foto_url, observacoes, criado_em	PK: id; FK: usuario_id	Clientes do profissional. foto_url aponta para o Supabase Storage.
simulacoes	id, cliente_id, usuario_id, img_entrada_url, img_saida_url, parametros_json, modelo_ia, tempo_ms, criado_em	PK: id; FK: cliente_id, usuario_id	Registro de cada simulação. parametros_json armazena cor, estilo e referência. usuario_id permite auditoria por profissional.
historico_servicos	id, cliente_id, simulacao_id, descricao, data_servico, observacoes	PK: id; FK: cliente_id; FK opt: simulacao_id	Atendimentos realizados. Vínculo com simulação é opcional; pode haver atendimento sem simulação prévia.
agendamentos	id, cliente_id, usuario_id, data_hora, servico, status, observacoes	PK: id; FK: cliente_id, usuario_id	Agenda do profissional. Status: pendente, confirmado, cancelado ou concluído.

Tabela 4. Entidades do banco de dados com atributos, tipos e relacionamentos. Fonte: elaborado pelo autor.

5.7 Requisitos funcionais e modelagem do fluxo de decisão

Complementarmente à sistematização por identificador apresentada na seção 5.3, é útil descrever o fluxo funcional de ponta a ponta que conecta os módulos do sistema. Na modelagem funcional, o fluxo principal inicia-se com a autenticação do profissional, seguida da seleção ou cadastro do cliente. Na sequência, a imagem é capturada, parametrizada e enviada ao serviço de IA. Após o recebimento do resultado, o usuário pode salvá-lo no histórico, registrar

observações e, se necessário, vinculá-lo a um agendamento ou a um serviço futuro. Esse encadeamento favorece a rastreabilidade da decisão estética e cria uma base de dados útil para atendimentos posteriores.

Como requisitos não funcionais transversais a esse fluxo, destacam-se a usabilidade para operação rápida durante o atendimento, a confiabilidade mínima para evitar perda de registros, a segurança no transporte e armazenamento de dados, a transparência sobre os limites da simulação e o desempenho percebido como adequado, mesmo com latência variável decorrente do processamento externo. Esses critérios já estão formalizados, com métricas mensuráveis, nas Tabelas 1 e 2.

5.8 Pipeline de simulação capilar

O pipeline de simulação compreende seis passos distribuídos entre os cinco participantes do sistema: Profissional (Mobile), Backend (FastAPI), Supabase Storage, PostgreSQL e Replicate API. O fluxo inicia-se com o envio da foto e dos parâmetros pelo mobile; o backend realiza a validação local da imagem, salva o original no Storage, executa o pré-processamento e aciona a API de IA. Após receber a imagem simulada, o backend a persiste no Storage e registra os metadados da simulação no banco. O mobile recebe a URL assinada e exibe o resultado. O salvamento no histórico de atendimentos é uma ação opcional, iniciada pelo profissional após avaliar o resultado.

Em termos de etapas observáveis pelo usuário, o pipeline pode ser descrito da seguinte forma: (1) captura da foto do usuário por câmera ou seleção na galeria; (2) verificação preliminar da imagem quanto a formato, resolução mínima e enquadramento aceitável; (3) seleção de referência de corte ou estilo e definição do parâmetro de cor; (4) pré-processamento da imagem, com redimensionamento, normalização e preparação dos parâmetros de entrada da inferência; (5) envio da solicitação ao serviço de IA e recepção da imagem simulada; e (6) exibição do resultado no aplicativo, com opção de vinculação ao histórico e ao atendimento do cliente.

A Figura 1 apresenta o diagrama de sequência UML correspondente a esse pipeline, incluindo o fluxo alternativo de rejeição de imagem inválida (inferido a partir dos critérios de qualidade mínima descritos na seção 4.2, ainda que não explicitado como passo numerado nesta seção) e o fragmento opcional de vínculo ao histórico.

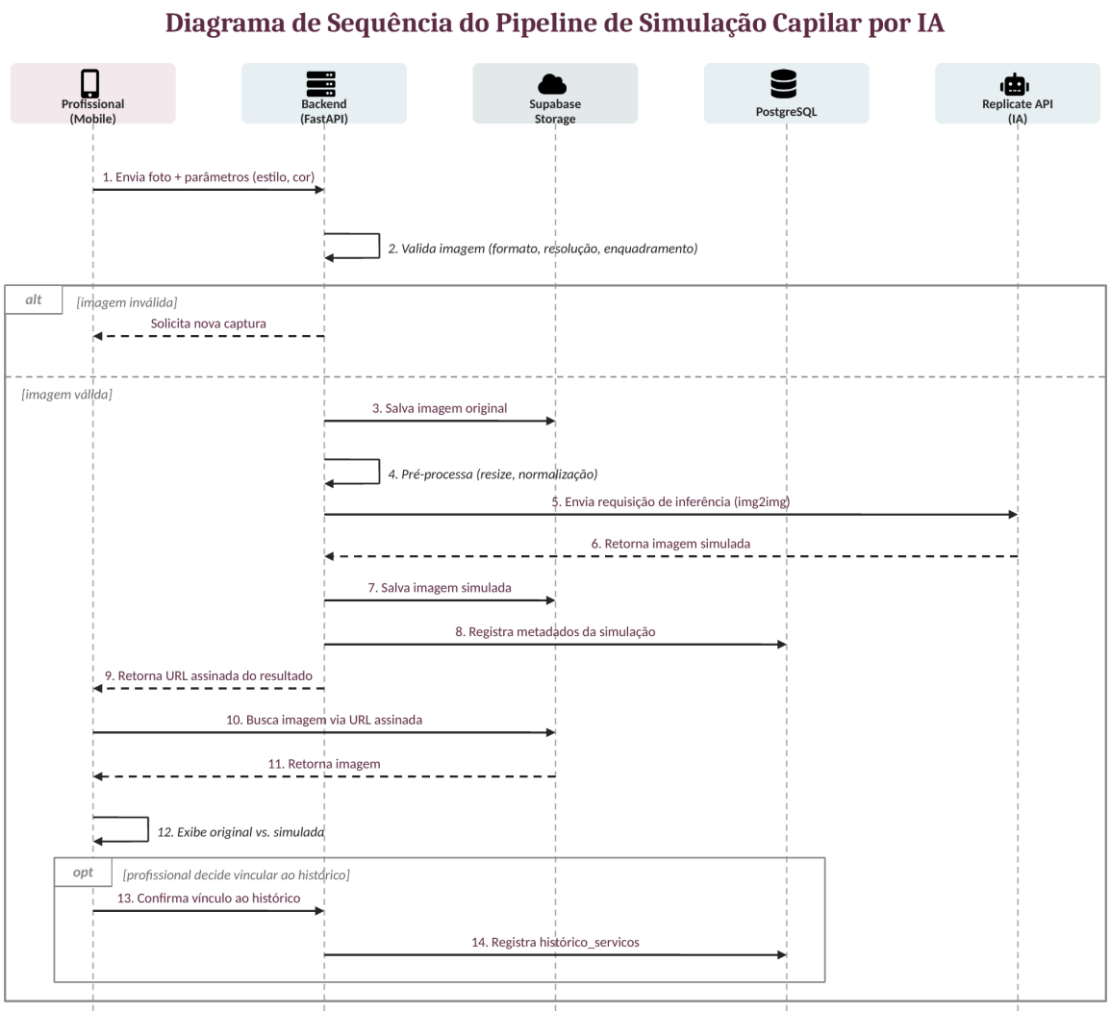


Figura 1. Diagrama de sequência do pipeline de simulação capilar. Fonte: elaborado pelo autor.

5.9 Protótipo de telas: wireframes descritivos

Na ausência de protótipo visual em execução, as telas do sistema são descritas textualmente abaixo, compondo o wireframe conceitual do MVP, conforme sistematizado na Tabela 5. A tela T0 foi incluída nesta revisão para que o requisito de consentimento explícito (RNF05, seção 5.11) tenha um ponto de captura concreto na interface, e não apenas uma diretriz textual.

Tela	Elementos Principais	Ação Principal
T0 - Consentimento	Texto resumido da finalidade do tratamento de imagem, link para a política de privacidade, caixa de marcação de aceite.	Registrar o consentimento explícito do profissional antes do primeiro uso da câmera, conforme LGPD, art. 7º e 11.
T1 - Login	Campos e-mail e senha; botão Entrar; link Recuperar senha.	Autenticar o profissional via Supabase Auth e redirecionar ao Dashboard.
T2 - Dashboard	Cards resumo: clientes cadastrados, simulações do dia, próximos agendamentos.	Visão geral rápida do dia de atendimento.

T3 - Lista de Clientes	Barra de busca, lista com foto miniatura, nome e data do último atendimento.	Selecionar cliente para ver perfil ou cadastrar novo.
T4 - Perfil do Cliente	Foto, dados, histórico de serviços em cards, galeria de simulações anteriores.	Iniciar nova simulação ou registrar atendimento.
T5 - Simulador: Captura	Câmera ao vivo com guia de enquadramento, lembrete de consentimento já registrado, botão capturar ou escolher da galeria.	Obter foto de boa qualidade para envio à IA.
T6 - Simulador: Parâmetros	Grid de estilos de corte (miniaturas), seletor de cor (paleta), campo de observações livres.	Parametrizar a simulação antes do envio.
T7 - Simulador: Resultado	Imagem original e simulada lado a lado, indicador de progresso, aviso de que o resultado é uma aproximação visual, botões Salvar e Tentar Novamente.	Avaliar o resultado e vincular ao histórico do cliente.
T8 - Agenda	Calendário mensal, lista de compromissos do dia, botão novo agendamento.	Gerenciar a agenda de atendimentos.

Tabela 5. Wireframes descritivos das telas do protótipo. Fonte: elaborado pelo autor.

5.10 Instrumentos de coleta e método de validação do sistema

A validação do protótipo combinará abordagens qualitativas e quantitativas, com um grupo de 5 a 10 participantes recrutados entre profissionais de beleza e clientes de pequenos salões da região. Esse tamanho de amostra é compatível com estudos exploratórios em TCC e com a recomendação de Nielsen (1994) de que testes com 5 a 10 usuários identificam a maioria dos problemas de usabilidade de um sistema, o que confere base metodológica sólida para a escala adotada neste projeto.

Serão utilizados três instrumentos principais: (i) roteiro observacional para execução de tarefas no aplicativo; (ii) questionário estruturado com escala Likert de cinco pontos para mensurar utilidade percebida, facilidade de uso, clareza do fluxo e confiança na simulação (LIKERT, 1932); e (iii) campo aberto para comentários qualitativos sobre dificuldades, limitações e sugestões. A Tabela 6 relaciona as dimensões avaliadas, os instrumentos correspondentes e os indicadores observados em cada uma.

Dimensão	Instrumento	Indicadores
Qualidade visual	Questionário Likert (1-5)	Naturalidade, coerência de cor, preservação de identidade facial.
Utilidade percebida	Questionário TAM (DAVIS, 1989)	A simulação ajuda a decidir antes de executar o serviço?
Usabilidade	Observação + SUS adaptado	Facilidade de navegação, clareza do fluxo, erros cometidos.
Desempenho percebido	Questionário + cronômetro	Tempo de resposta considerado aceitável no contexto de atendimento.

Confiança no sistema	Questões abertas	O usuário compreende que a simulação é uma aproximação visual, não uma previsão exata?

Tabela 6. Dimensões e instrumentos de avaliação. Fonte: elaborado pelo autor.

Os dados quantitativos serão organizados por meio de estatística descritiva, com uso de médias, frequências e dispersão das respostas. Os dados qualitativos serão submetidos a categorização temática, com ênfase em recorrências relacionadas a naturalidade visual, compreensão do processo, valor para o atendimento e problemas percebidos. A combinação desses dois conjuntos de evidências busca fortalecer a interpretação dos resultados mesmo em cenário de amostra reduzida (CRESWELL; PLANO CLARK, 2017).

5.11 Aspectos éticos, privacidade e LGPD

Como o sistema manipula imagens faciais e dados pessoais, serão adotadas as seguintes práticas:

- Consentimento explícito e informado para captura e processamento de imagem, registrado na tela T0 (Tabela 5), em conformidade com a Lei nº 13.709/2018 (LGPD).
- Armazenamento criptografado no Supabase Storage (AES-256 em repouso, TLS 1.3 em trânsito).
- Imagens vinculadas exclusivamente ao profissional-proprietário, sem compartilhamento com terceiros.
- Política de retenção com exclusão sob demanda pelo usuário (LGPD, art. 18).
- Comunicação transparente de que a simulação é uma aproximação visual sem finalidade diagnóstica ou prescritiva, conforme reforçado na tela T7 (Tabela 5).

Um ponto que merece esclarecimento conceitual é a natureza jurídica da fotografia capilar à luz da LGPD. A lei classifica como dado pessoal sensível o dado biométrico vinculado a uma pessoa natural (BRASIL, 2018, art. 5º, II), categoria normalmente associada a sistemas que extraem um padrão biométrico estável (template) para fins de identificação ou autenticação de identidade, como reconhecimento facial de acesso ou impressões digitais. Uma fotografia comum, por sua vez, é tratada como dado pessoal comum quando sua finalidade não é identificar ou autenticar o titular (BECOMPLIANCE, 2025). O sistema aqui proposto processa a geometria facial apenas de forma transitória, para fins de segmentação da região capilar, sem armazenar template biométrico nem realizar reconhecimento ou autenticação de identidade, o que aproxima a fotografia de entrada da categoria de dado pessoal comum. Ainda assim, como

a Autoridade Nacional de Proteção de Dados (ANPD) não publicou, até a data deste pré-projeto, regulamentação específica sobre dados biométricos, prevista para ser concluída em 2026 (CONFIDATA, 2026), o projeto adota por precaução o regime de proteção mais rigoroso, tratando toda fotografia capturada pelo aplicativo como dado pessoal sensível para fins de base legal, segurança e retenção, independentemente da classificação técnica final que venha a ser adotada pela ANPD.

Entre as limitações previstas estão a dependência de serviço externo de IA, a sensibilidade do resultado à qualidade da imagem de entrada, a eventual latência da inferência e possíveis vieses visuais associados à representatividade das bases dos modelos utilizados. Essas limitações serão explicitadas na análise final, de modo a orientar interpretações prudentes dos resultados obtidos e a balizar as diretrizes de evolução do trabalho final.

5.12 Riscos e estratégias de mitigação

A condução de um projeto que depende de serviço externo de IA, prazo acadêmico fixo e validação com usuários reais expõe o trabalho a riscos de naturezas distintas, que devem ser antecipados para reduzir a probabilidade de comprometimento do cronograma ou da qualidade do produto final.

No plano técnico, o principal risco é a indisponibilidade ou a degradação de desempenho do serviço de inferência externo (Replicate API), o que afetaria diretamente o requisito RNF02. Esse risco é ampliado pelo fato de o sistema depender também do Supabase para autenticação, dados e armazenamento: a disponibilidade efetiva do RNF04 está sujeita à soma dos riscos de dois provedores externos, e não de apenas um. Como mitigação principal, a arquitetura adota o desacoplamento descrito na seção 5.5, de modo que o cadastro de clientes, o histórico e a agenda continuem operacionais mesmo quando o Replicate API estiver indisponível. Complementarmente, o backend será desenhado com tratamento de erro explícito, mensagens claras ao usuário em caso de falha temporária e possibilidade de nova tentativa sem perda dos dados já inseridos. Um risco correlato é a variação de qualidade do resultado conforme a imagem de entrada, mitigado pelas validações de pré-processamento descritas na seção 4.2.

No plano de cronograma, o risco mais relevante é o atraso na fase de desenvolvimento iterativo, especialmente na integração entre backend e serviço de IA, etapa historicamente sujeita a retrabalho em projetos que dependem de APIs de terceiros. A estratégia de mitigação central é a priorização MoSCoW: em caso de atraso, o esforço é redirecionado às

funcionalidades classificadas como must have, garantindo a entrega de um protótipo mínimo viável dentro do prazo, ainda que funcionalidades should have ou could have sejam adiadas para o TCC final.

No plano metodológico, o risco de maior atenção é a dificuldade de recrutar entre 5 e 10 participantes representativos do público-alvo dentro da janela de tempo disponível para os testes. Para mitigar esse risco, o recrutamento será iniciado com antecedência, junto a profissionais e clientes de salões da região de Santa Maria, e o roteiro de avaliação foi desenhado para ser executado em sessões curtas, reduzindo o custo de participação e ampliando a probabilidade de adesão.

Por fim, no plano ético, o risco mais sensível envolve o tratamento de imagens faciais. A mitigação adotada combina consentimento explícito registrado na tela T0, minimização de dados, criptografia em repouso e em trânsito, e política de exclusão sob demanda, conforme detalhado na seção 5.11, reduzindo a exposição do projeto a riscos de conformidade com a LGPD.

6 RESULTADOS PARCIAIS E ESPERADOS

6.1 Resultados parciais

Como resultados parciais, o projeto já apresenta:

- Definição completa do escopo funcional e das tecnologias de implementação.
- Descrição detalhada da arquitetura do sistema, com responsabilidades por camada e esclarecimento do fluxo de autenticação entre Supabase Auth e FastAPI.
- Modelagem do banco de dados com cinco entidades, atributos, tipos e relacionamentos definidos.
- Sistematização das relações entre entidades e do fluxo de dados do pipeline de simulação, incluindo o diagrama de sequência UML apresentado na Figura 1 (seção 5.8).
- Priorização MoSCoW das funcionalidades com critérios de aceitação definidos.
- Recorte metodológico consolidado, com critérios de avaliação e diretrizes de privacidade, incluindo a delimitação da fotografia capilar como dado pessoal sensível por precaução.

- Wireframes descritivos de todas as telas do protótipo, incluindo a tela de consentimento (T0).

Esses artefatos constituem a base técnica para o início do desenvolvimento incremental em julho de 2026, reduzindo riscos de retrabalho e estabelecendo um contrato claro entre escopo, prazo e qualidade esperada.

6.2 Entrega do sistema: o que o protótipo fará

Ao final do projeto, o protótipo entregará:

- Autenticação segura do profissional, com sessão persistente via Supabase Auth e validação de token pelo backend.
- CRUD completo de clientes, com foto, dados de contato e observações.
- Módulo de simulação capilar: captura ou seleção de foto, parametrização de estilo e cor, envio à API de IA e exibição do resultado lado a lado com o original.
- Persistência da simulação no Supabase Storage, vinculada ao cliente, com metadados de parâmetros, modelo de IA e tempo de processamento.
- Histórico de atendimentos consultável por cliente, com possibilidade de recuperar simulações anteriores.
- Agenda básica de serviços, com criação, edição e cancelamento de compromissos.

O protótipo não incluirá recomendação automática de penteado por perfil biométrico, análise de tendências agregadas, integração com pagamentos ou suporte a múltiplos usuários simultâneos por conta, funcionalidades previstas para versões futuras.

6.3 Resultados esperados

Em termos de contribuição prática, espera-se demonstrar que a combinação entre IA visual e gestão operacional pode qualificar a comunicação entre profissional e cliente, reduzir o retrabalho na decisão estética e simplificar a rotina do profissional, ao centralizar clientes, histórico e agenda em um único aplicativo. Em termos acadêmicos, o trabalho contribui com um estudo aplicado sobre a integração entre modelos generativos e sistemas de informação orientados a serviços personalizados, sistematizando diretrizes de design reutilizáveis para projetos semelhantes, conforme delimitado na seção 5.1.

Como produto técnico-científico, espera-se ainda produzir documentação reprodutível da arquitetura, das decisões de implementação e das lições aprendidas, permitindo a continuidade do projeto no TCC final com menor retrabalho, em especial no que se refere à evolução do pipeline de IA e à ampliação da amostra de validação.

6.4 Indicadores de sucesso

Para caracterizar o sucesso mínimo do protótipo, serão considerados:

- Execução estável do fluxo completo de simulação, sem falhas críticas em ao menos 90% das tentativas durante a avaliação.
- Média igual ou superior a 3,5 (escala Likert de 1 a 5) nos itens de utilidade percebida e qualidade visual.
- Registro consistente de dados de cliente, histórico e agenda, sem perda de informação.
- Tempo de resposta da simulação percebido como aceitável por ao menos 70% dos participantes.

7 CRONOGRAMA DE ATIVIDADES

O cronograma a seguir organiza o desenvolvimento do projeto no período de julho a novembro de 2026, contemplando as atividades macro e sua distribuição mensal. As fases seguem a estrutura iterativa do DSDM, com entregas verificáveis ao final de cada ciclo. A Fase 1 e o início da Fase 2 são executados em paralelo, e a escrita da monografia inicia em outubro, concomitante aos testes, de modo a garantir a entrega final em novembro de 2026.

Atividade	Jul/26	Ago/26	Set/26	Out/26	Nov/26
Revisão e consolidação do referencial teórico	X				
Levantamento e validação de requisitos (RF + RNF)	X				
Modelagem do banco de dados e diagramas (DER e Sequência)	X				
Configuração do ambiente (Docker, Supabase, Expo, Git)	X				
Criação do schema PostgreSQL e migrações iniciais	X	X			
Implementação da autenticação Supabase Auth + validação JWT no FastAPI		X			
CRUD de clientes e histórico no backend (FastAPI)		X			
Telas de autenticação e navegação base		X			

Módulo de clientes (listagem, perfil, cadastro, edição)		X	X		
Módulo de histórico de atendimentos			X		
Módulo de agenda de serviços			X		
Pipeline de pré-processamento de imagem (validação, resize, normalização)			X	X	
Integração com Replicate API (img2img / inpainting capilar)				X	
Tela do Simulador no mobile (captura, parâmetros, resultado, salvar)				X	
Testes técnicos internos (unitários, integração, carga)				X	
Avaliação com usuários: observação e questionário Likert/TAM (5 a 10 participantes)				X	X
Análise dos dados e ajustes prioritários no protótipo					X
Escrita da monografia (paralela à fase de testes)				X	X
Revisão final com orientador e correções					X

Quadro 1. Cronograma de Atividades (jul.-nov. 2026). Fonte: elaborado pelo autor.

Os marcos a seguir representam entregas verificáveis que sinalizam o avanço do projeto.

Marco	Data-alvo	Entregável / Critério de Conclusão
M1	Jul/2026	Referencial teórico, requisitos (RF/RNF), DER, diagrama de sequência e ambiente de desenvolvimento configurados.
M2	Ago/2026	Backend base e banco de dados operacionais, com autenticação e CRUD de clientes funcionando e testados.
M3	Set/2026	Protótipo de gestão completo (sem IA): MVP de CRM operacional pronto para testes internos.
M4	Out/2026	Protótipo funcional completo com IA integrada (prova de conceito): aplicativo com simulação capilar e gestão operacional integradas.
M5	Nov/2026	Validação concluída e monografia em revisão: dados analisados e rascunho submetido para revisão final.

Quadro 2. Marcos (milestones) do projeto. Fonte: elaborado pelo autor.

O cronograma considera o desenvolvimento individual, com dedicação estimada de 15 a 20 horas semanais ao projeto. Em caso de atraso em uma fase, a prioridade de recuperação recairá sobre as funcionalidades must have, garantindo que o protótipo mínimo viável seja entregue dentro do prazo acadêmico de novembro de 2026.

REFERÊNCIAS BIBLIOGRÁFICAS

ABDI - AGÊNCIA BRASILEIRA DE DESENVOLVIMENTO INDUSTRIAL; SEBRAE - SERVIÇO BRASILEIRO DE APOIO ÀS MICRO E PEQUENAS EMPRESAS. Mapa de Maturidade Digital dos Pequenos Negócios 2024. Brasília: ABDI; Sebrae, 2024. Disponível em:

https://www.abdi.com.br/mapa-de-maturidade-digital-2024-cerca-de-50-dos-pequenos-negocios-usam-midias-digitais-para-vender-produtos-ou-servicos/. Acesso em: 22 jun. 2026.

ABIHPEC - ASSOCIAÇÃO BRASILEIRA DA INDÚSTRIA DE HIGIENE PESSOAL, PERFUMARIA E COSMÉTICOS. Panorama do Setor de Beleza e Cuidados Pessoais 2025. São Paulo: ABIHPEC, 2025. Disponível em: https://abihpec.org.br/site2019/wp-content/uploads/2025/04/Panorama-do-Setor-de-Beleza-e-Cuidados-Pessoais_12.08.25_Port.pdf. Acesso em: 22 jun. 2026.

AGILE BUSINESS CONSORTIUM. The DSDM Agile Project Framework Handbook. Ashford: Agile Business Consortium, 2014.

BECOMPLIANCE. LGPD e o uso de imagem e voz: são dados pessoais sensíveis? Entenda o risco. 2025. Disponível em: https://becompliance.com/lgpd-e-o-uso-de-imagem-e-voz-sao-dados-pessoais-sensiveis-entenda-o-risco/. Acesso em: 22 jun. 2026.

BJØRN-HANSEN, Andreas; GRØNLI, Tor-Morten; GHINEA, Gheorghita. A Survey and Taxonomy of Core Concepts and Research Challenges in Cross-Platform Mobile Development. ACM Computing Surveys, v. 53, n. 4, p. 1-34, 2020.

BOOKSY. Recursos para profissionais de beleza e bem-estar. 2026. Disponível em: https://biz.booksy.com/en-us/features. Acesso em: 22 jun. 2026.

BRASIL. Lei nº 13.709, de 14 de agosto de 2018. Lei Geral de Proteção de Dados Pessoais (LGPD). Diário Oficial da União, Brasília, DF, 14 ago. 2018.

CONFIDATA. LGPD e dados biométricos: reconhecimento facial, digital e voz. 2026. Disponível em: https://confidata.com.br/blog/lgpd-dados-biometricos-reconhecimento-facial-digital. Acesso em: 22 jun. 2026.

COSTA, Lais Santiago da et al. Assessing the digital maturity of micro and small enterprises: a focus on an emerging market. Procedia Computer Science, v. 200, p. 175-184, 2022.

CRESWELL, John W.; PLANO CLARK, Vicki L. Designing and Conducting Mixed Methods Research. 3. ed. Thousand Oaks: SAGE Publications, 2017.

DAVIS, Fred D. Perceived Usefulness, Perceived Ease of Use, and User Acceptance of Information Technology. MIS Quarterly, v. 13, n. 3, p. 319-340, 1989.

HE, Kaiming et al. Mask R-CNN. In: Proceedings of the IEEE International Conference on Computer Vision (ICCV). 2017. p. 2961-2969.

HEVNER, Alan R. et al. Design Science in Information Systems Research. MIS Quarterly, v. 28, n. 1, p. 75-105, 2004.

HO, Jonathan; JAIN, Ajay; ABBEEL, Pieter. Denoising Diffusion Probabilistic Models. Advances in Neural Information Processing Systems, v. 33, p. 6840-6851, 2020.

INTERNATIONAL ORGANIZATION FOR STANDARDIZATION. Ergonomics of human-system interaction, Part 11: Usability: Definitions and concepts. Geneva, 2018. ISO 9241-11:2018.

JANG, Seong-Geun; MAN, Qiaoyue; CHO, Young-Im. Development of a Hairstyle Conversion System Based on Mask R-CNN. Electronics, v. 11, n. 12, p. 1887, 2022.

KHWANMUANG, Sasikarn et al. StyleGAN Salon: Multi-View Latent Optimization for Pose-Invariant Hairstyle Transfer. In: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops. 2023. p. 8609-8618.

KOKONG, Lefa N.; NAIDOO, Sugandren. Digitalisation of the professional hairdressing industry and the impact on value chain stakeholders. South African Journal of Information Management, v. 24, n. 1, p. 1-13, 2022.

LIKERT, Rensis. A Technique for the Measurement of Attitudes. New York: Archives of Psychology Press, 1932.

NAIR, Gayathry G.; VARGHESE, Lisha. Virtual Try On Hairstyles Using Augmented Reality. In: Proceedings of the National Conference on Emerging Computer Applications (NCECA 2025). Kerala, India, 2025. p. 479-483.

NIELSEN, Jakob. Usability Engineering. San Francisco: Morgan Kaufmann, 1994.

PAYNE, Adrian; FROW, Pennie. A Strategic Framework for Customer Relationship Management. Journal of Marketing, v. 69, n. 4, p. 167-176, 2005.

PERFECT CORP. YouCam Makeup: Face Editor. 2026. Disponível em: https://www.perfectcorp.com/consumer/apps/ymk. Acesso em: 22 jun. 2026.

ROMBACH, Robin et al. High-Resolution Image Synthesis with Latent Diffusion Models. In: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2022. p. 10684-10695.

RUSSELL, Stuart; NORVIG, Peter. Artificial Intelligence: A Modern Approach. 4. ed. Hoboken: Pearson, 2021.

SKLYAROVA, Vanessa et al. Text-Conditioned Generative Model of 3D Strand-based Human Hairstyles. In: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2024. p. 4703-4712.

SUNG, Changjo; CHIN, Seongah. Contactless Multi-User Virtual Hair Design Synthesis. Electronics, v. 12, n. 17, p. 3686, 2023.

ZHAO, Huihuang et al. HairManip: High quality hair manipulation via hair element disentangling. Pattern Recognition, v. 147, p. 110132, 2024.